

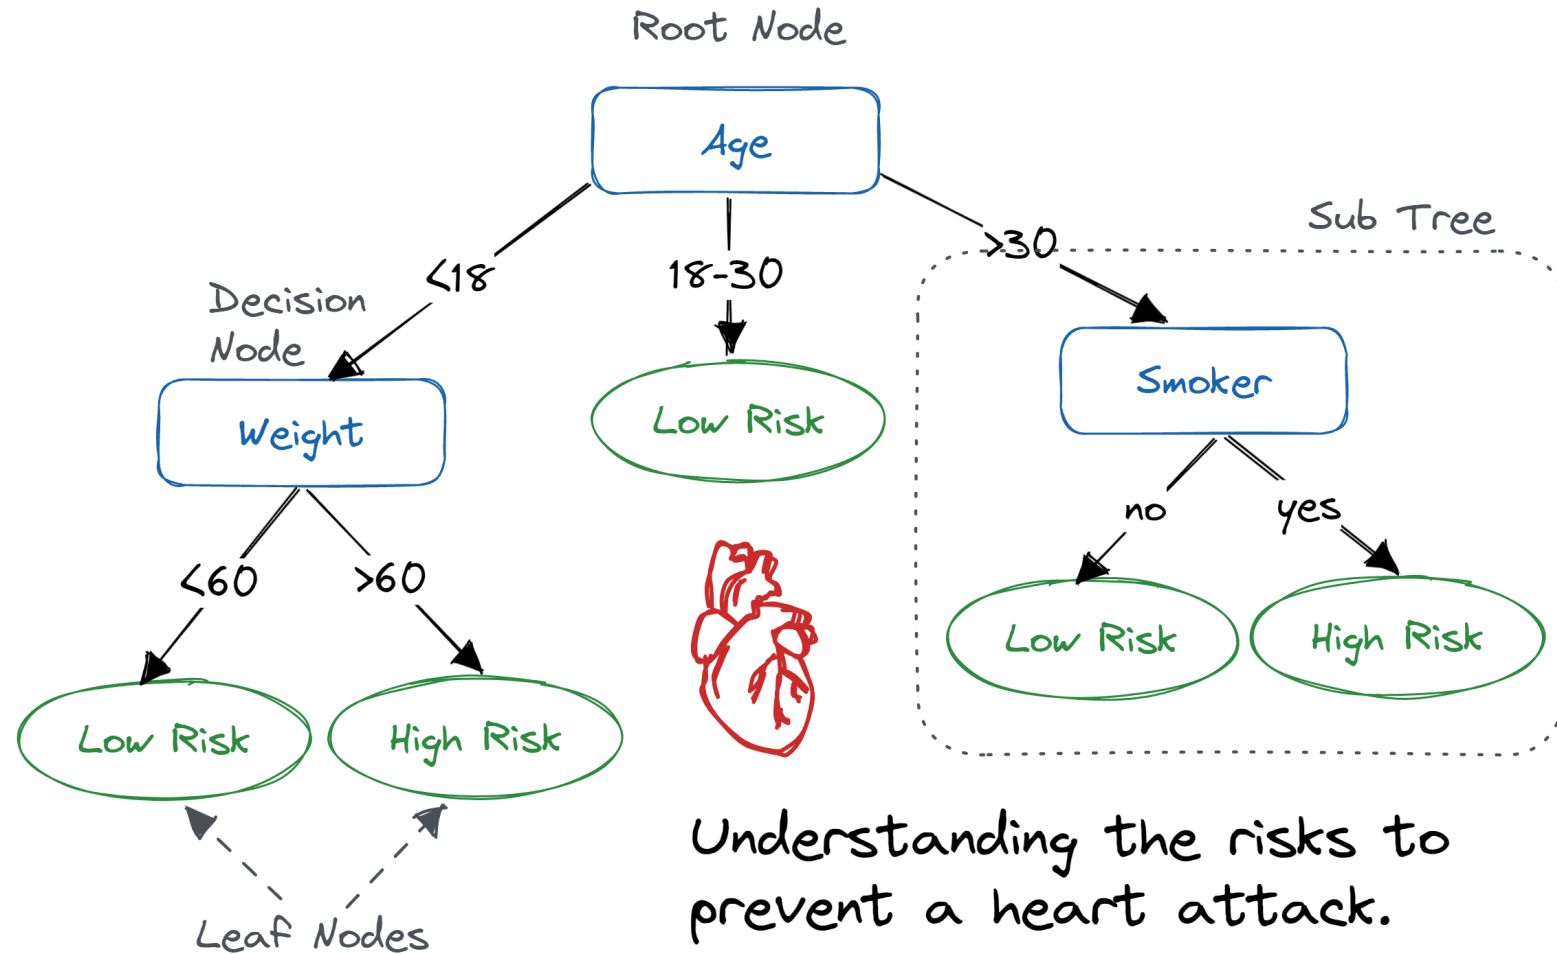
Ансамбли моделей

Лекция 5

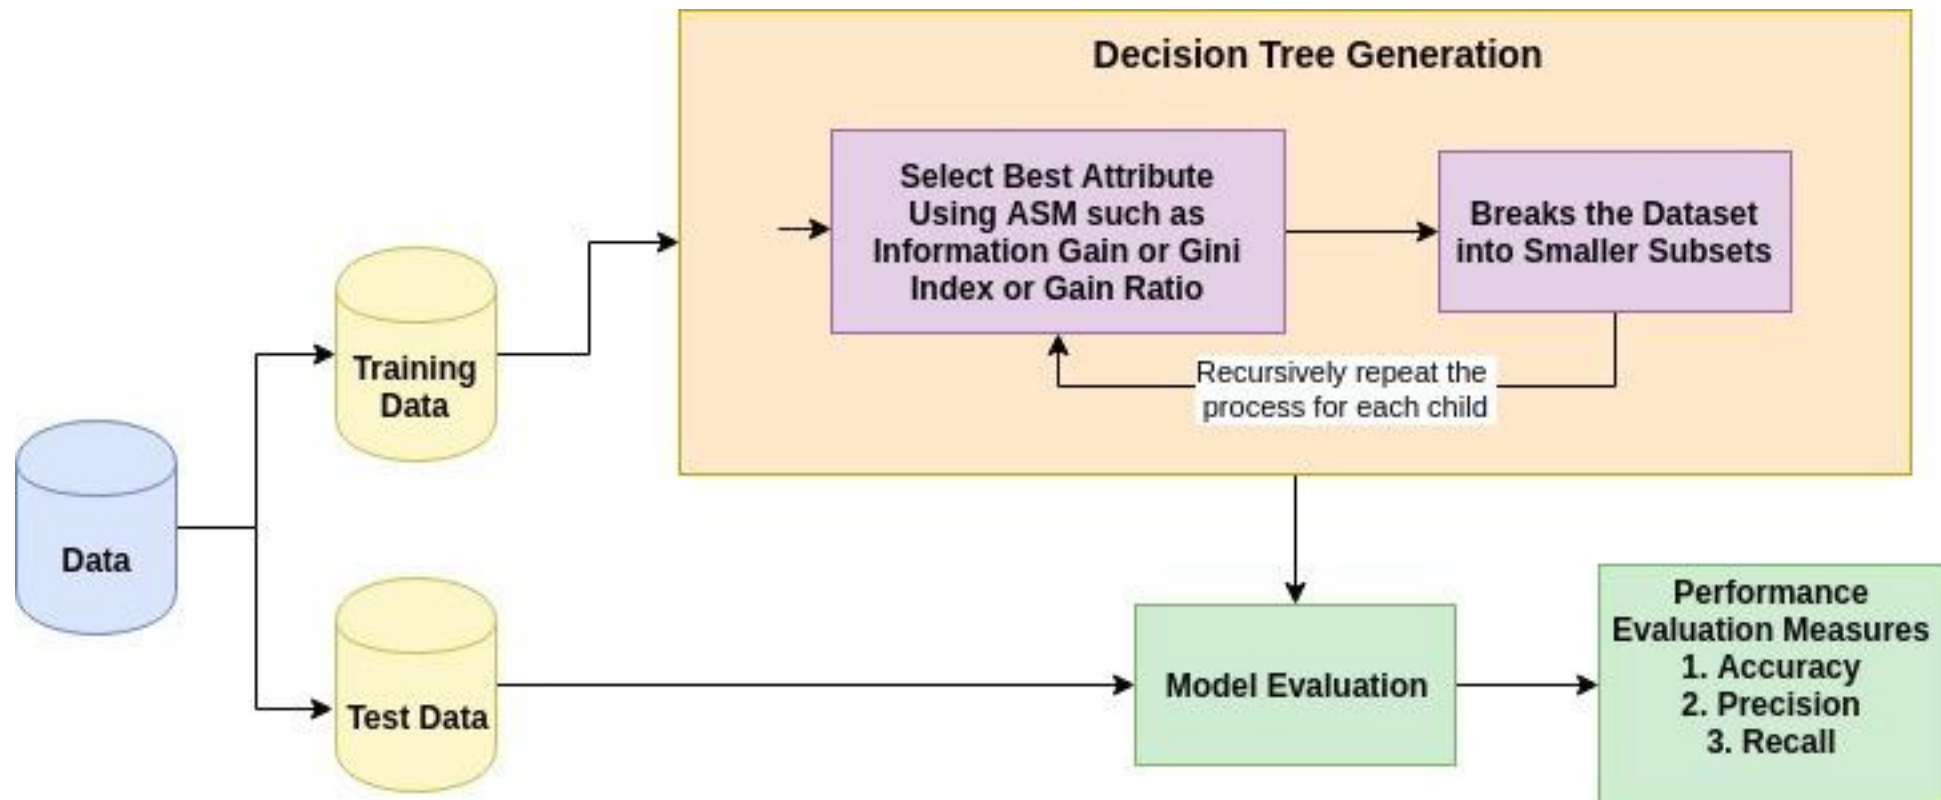
Тест



Повторение. Решающие деревья



Повторение. Решающие деревья



Повторение. Решающие деревья

Регрессия:

$$H(R) = \frac{1}{N} \sum_{i=0}^N \left(y_i - \frac{1}{N} \sum_{i=0}^N y_i \right)^2 \rightarrow \min$$

Классификация:

$$H(R) = - \sum_{k=1}^K p_k (1 - p_k) \rightarrow \min$$

$$H(R) = - \sum_{k=1}^K p_k \log p_k \rightarrow \min$$

Семплирование выборки

$\mathbb{X} = (x_i, y_i)_{i=1}^l$ – исходная выборка

Создаем n выборок размера l : X_1, X_2, \dots, X_n

Обучаем n моделей на каждой из выборок: b_1, b_2, \dots, b_n

Если мы знаем распределение объектов (с какой вероятностью каждый объект попадет в каждую из выборок X_1, X_2, \dots, X_n) $p(x)$

Истинные ответы модели – $y(x)$


Ошибки

Для каждой модели запишем математическое ожидание
среднеквадратичной ошибки как


$$\mathbb{E}_x \left(b_j(x) - y(x) \right)^2 = \mathbb{E}_x \varepsilon_j^2(x)$$

Два предположения:

1. $\mathbb{E}_x \varepsilon_j(x) = 0$
2. $\mathbb{E}_x \left(\varepsilon_j(x) \cdot \varepsilon_i(x) \right) = 0, i \neq j$



Еще про распределение ошибок



Байка про бычка и мудрость толпы

Пример точечной оценки непрерывной величины

Фрэнсис Гальтон гулял в 1906 по сельской ярмарке и обратил внимание на конкурс, где участвовавшему человеку предлагалось оценить вес быка.

Почти 800 человек приняло участие в конкурсе, Гальтон собрал оценки каждого человека и обнаружил, что медианное значение составляло 1207 фунтов, в то время как истинный вес бычка был 1198 фунтов.

Для задачи классификации. Теорема Кондорсе о присяжных

Вводные:

M – количество присяжных

p – вероятность правильного решения одного эксперта

m – минимальное большинство членов жюри $m = \frac{N}{2} + 1$

Тогда вероятность правильного решения всего жюри:


$$R = \sum_{i=m}^M C_M^i p^i (1-p)^{M-i}$$

Теорема Кондорсе о присяжных

Вероятность правильного решения всего жюри будет выше при:

1. Большем количестве присяжных M
2. Большой вероятности правильного решения одного эксперта p

Важно: оценки экспертов должны быть **независимы**



Усредненная модель

Применим новую модель, которая будет представлять собой усредненные предсказания всех n моделей.

$$a(x) = \frac{1}{n} \sum_{j=1}^n b_j(x)$$

Тогда ошибка:

$$\mathbb{E}_x \left(b_j(x) - y(x) \right)^2 = \mathbb{E}_x \left(\frac{1}{n} \sum_{j=1}^n b_j(x) - y(x) \right)^2 = \mathbb{E}_x \left(\frac{1}{n} \sum_{j=1}^n \varepsilon_j(x) \right)^2$$

Получаем улучшение

$$\begin{aligned}\mathbb{E}_x \left(\frac{1}{n} \sum_{j=1}^n \varepsilon_j(x) \right)^2 &= \frac{1}{n^2} \mathbb{E}_x \left(\sum_{j=1}^n \varepsilon_j^2(x) + \sum_{i \neq j}^n (\varepsilon_i(x) \cdot \varepsilon_j(x)) \right)^2 \\ &= \frac{1}{n} \mathbb{E}_x \varepsilon_j^2(x)\end{aligned}$$

Разложение ошибки (смещение и разброс)

$\mathbb{X} = (x_i, y_i)_{i=1}^l$ – исходная выборка

Создаем n выборок размера l : X_1, X_2, \dots, X_n

Обучаем n моделей на каждой из выборок: b_1, b_2, \dots, b_n

Разложение ошибки (смещение и разброс)

Функционал ошибки на всех выборках запишем в виде:

$$Q(a) = \mathbb{E}_x \mathbb{E}_{X, \epsilon} [y(x, \epsilon) - a(x, X)]^2$$

где X – обучающая выборка

x – точка (объект) из тестового множества

$y(x, \epsilon) = f(x) + \epsilon$ – целевая зависимость, которую можем измерить с точностью до случайного шума ϵ

$a(x, X)$ – предсказание алгоритма, обученного на X , на объекте x

\mathbb{E}_x – математическое ожидание по всей тестовой выборке (среднее по всем тестовым объектам)

$\mathbb{E}_{X, \epsilon}$ – математическое ожидание по всем обучающим выборкам и случайному шуму ϵ

Разложение ошибки (смещение и разброс)



$$Q(a) = \mathbb{E}_x \text{bias}_X^2 a(x, X) + \mathbb{E}_x \mathbb{V}_X[a(x, X)] + \sigma^2$$

где $\text{bias}_X a(x, X) = f(x) - \mathbb{E}_x[a(x, X)]$ – **смещение**, показывает, насколько усредненная модель далека от истинной зависимости



$\mathbb{V}_X[a(x, X)] = \mathbb{E}_X[a(x, X) - \mathbb{E}_x[a(x, X)]]^2$ – **дисперсия**, показывает, насколько велико отклонение каждой отдельной модели от усредненной

$\sigma^2 = \mathbb{E}_X \mathbb{E}_\epsilon [y(x, \epsilon) - f(x)]^2$ – **неустраняемый шум** в данных



Линейная регрессия




Решающее дерево (глубина 2)




Решающее дерево (глубина None)



Разложение ошибки (смещение и разброс)




Разложение ошибки (смещение и разброс)



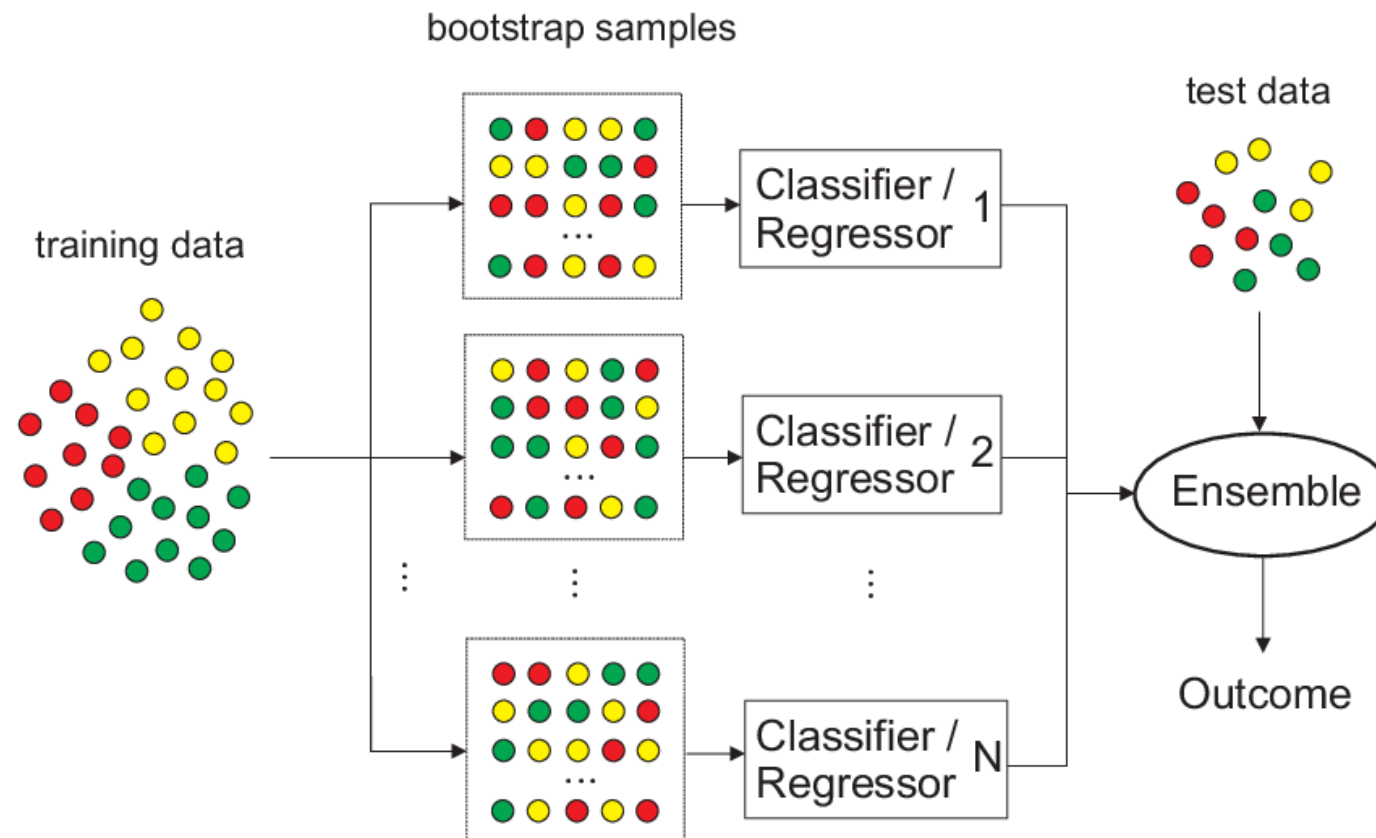
Бутстрап

Метод сэмплирования, при котором подвыборка формируется из основной выборки с возвращением



Случайный лес. Бэггинг

Бэггинг (bagging = bootstrap aggregating) – обучение моделей при помощи сэмплирования с возвращением.



Влияние на ошибку при использовании бэггинга

Результат работы ансамбля моделей:

$$a(x) = \frac{1}{n} \sum_{j=1}^n b_j(x)$$

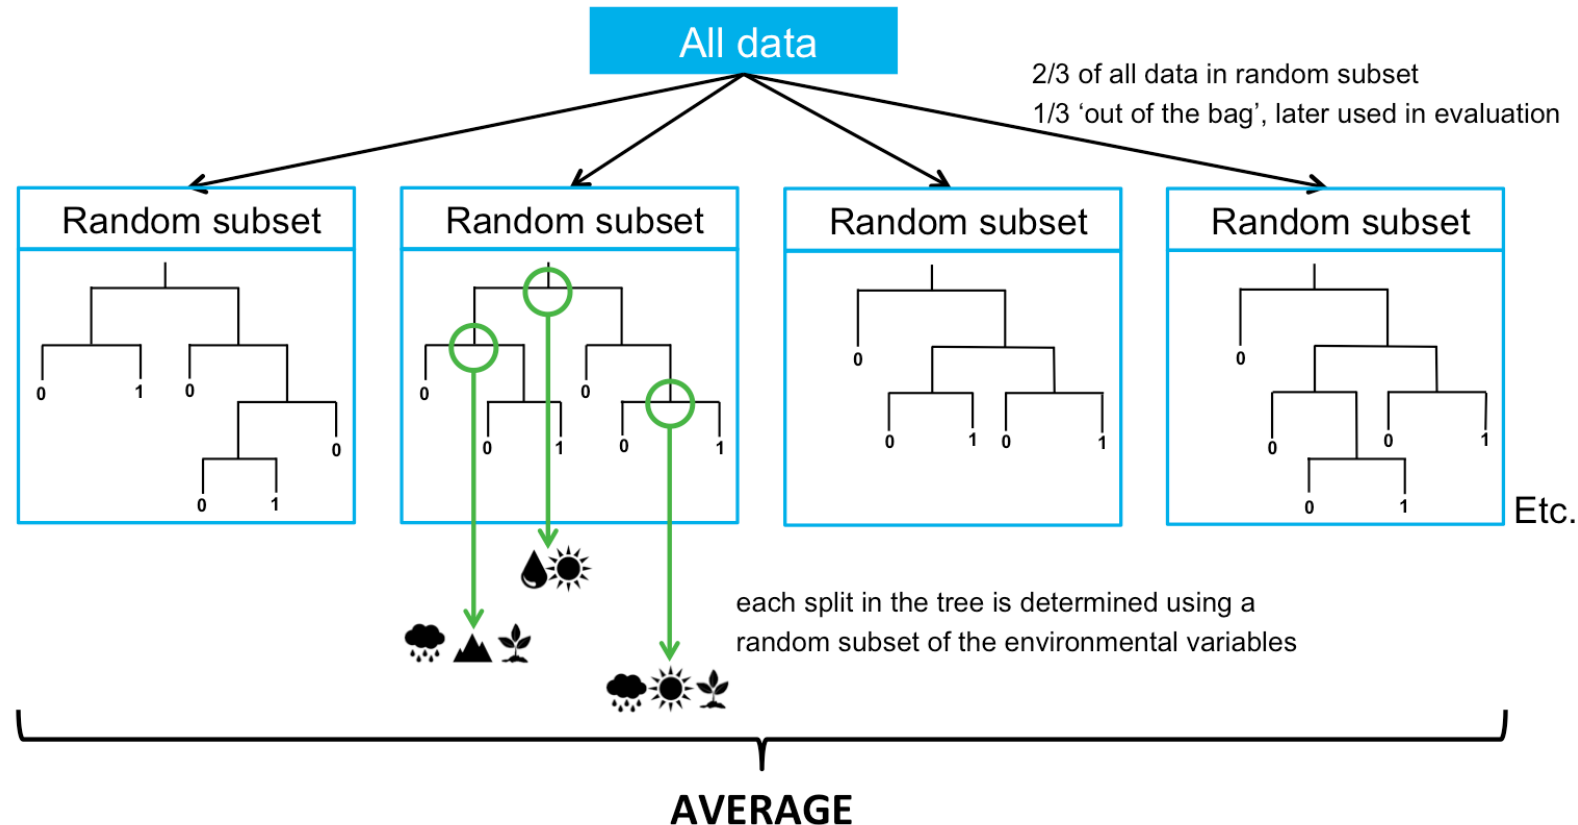
Смещение (bias) при использовании ансамбля моделей **не уменьшается**

Разброс (variance) при использовании ансамбля моделей **уменьшается**

Поэтому надо использовать в качестве **базовых моделей** такие, которые бы обладали **низким смещением** (разброс может быть большим)


Случайный лес. Требование №2

Необходима независимость базовых моделей




> find the set of predictor variables that produce the strongest classification model


Случайный лес. Требование №2



bagging
(sample instances)
max_samples=0.75,
bootstrap=True,
max_features=1.0,
bootstrap_features=False




random subspaces
(sample features)
max_samples=1.0,
bootstrap=False,
max_features=0.5,
bootstrap_features=True



random patches
(sample both)
max_samples=0.75,
bootstrap=True,
max_features=0.5,
bootstrap_features=True

Оценка Out-of-bag

OOBE



Важность признаков

